Cahier de Charge

Assistant Éducatif Multimodal Intelligent pour l'ENET'Com
RAG + Vision-Langage + Ontologie + Apprentissage par Renforcement

École Nationale d'Électronique et des Télécommunications de Sfax (ENET'Com)

3 octobre 2026

Table des matières

1 Titre et contexte du projet **2**
- 1.1 Titre du projet . . . 2
- 1.2 Contexte . . . 2
- 1.3 Parties prenantes . . . 2

2 Objectif général **3**

3 Objectifs spécifiques **4**

4 Description de la base de données **6**
- 4.1 Nature du catalogue existant . . . 6
- 4.2 Structure hiérarchique observée . . . 6
- 4.3 Statistiques mesurées sur le catalogue . . . 6
- 4.4 Problèmes de qualité à traiter (Phase 1) . . . 7
- 4.5 Schéma normalisé cible . . . 7

5 Méthodologie de travail : CRISP-DM **9**

6 Pipeline théorique (architecture cible) **10**

7 Pipeline pratique (mise en œuvre incrémentale) **12**

8 Tableau des livrables **14**

9 Ressources de recherche **15**
- 9.1 Référence structurante : MDKAG . . . 15
- 9.2 Autres fondements . . . 15

10 Contraintes, risques et reproductibilité **16**

Chapitre 1

Titre et contexte du projet

1.1 Titre du projet

Assistant Éducatif Multimodal, Personnalisé et Adaptatif pour l'ENET'Com : système de réponse aux questions étudiantes fondé sur le corpus pédagogique propre de l'école, combinant recherche augmentée par génération (RAG), compréhension vision-langage, graphe de connaissances disciplinaires (ontologie) et politique pédagogique adaptative (apprentissage par renforcement).

1.2 Contexte

L'ENET'Com dispose d'un corpus pédagogique riche (cours, TD, examens, corrections, supports de présentation, images, notes) actuellement dispersé sur Google Drive et référencé par un catalogue JSON hiérarchique. Les étudiants posent des questions multimodales (*ex. :* photo d'une diapositive, schéma d'architecture LSTM, équation, capture de code) qui exigent :

— des réponses **ancrées** dans les documents ENET'Com (avec citation de page),

— la compréhension conjointe **texte** + **image**,

— le raisonnement sur les **prérequis** (que faut-il savoir avant PCA, LSTM, etc.),

— une **adaptation** au niveau de l'étudiant (indice, simplification, exercice, remédiation).

Un simple robot conversationnel adossé à un LLM pré-entraîné ne satisfait aucune de ces exigences : il hallucine, ignore le corpus local et n'est ni évaluable ni adaptatif.

1.3 Parties prenantes

Étudiants, enseignants (fournisseurs et validateurs du corpus et de l'ontologie), équipe de développement/recherche, administration (accès Drive, confidentialité).

Chapitre 2

Objectif général

Concevoir, développer et évaluer de manière **incrémentale et scientifique** un assistant éducatif multimodal capable de :

1. répondre aux questions des étudiants **à partir des ressources pédagogiques de l'ENET'Com** (et non de la seule connaissance paramétrique du LLM),
2. comprendre des entrées **textuelles et visuelles** (diapositives, schémas, équations, tracés, captures de code),
3. raisonner sur une **ontologie / graphe de connaissances** disciplinaire (concepts, prérequis, objectifs, documents),
4. **adapter sa stratégie pédagogique** (expliquer, simplifier, donner un indice, recommander un prérequis, générer un exercice, corriger) à l'état de l'apprenant, avec une couche décisionnelle évaluée de type bandit/RL.

Le système final doit se comporter comme un **agent éducatif ancré, multimodal et adaptatif**, et non comme un simple dialogueur sur PDF.

Chapitre 3

Objectifs spécifiques

OS1 – Ingestion fiable du catalogue ENET'Com
Parcourir récursivement les catalogues JSON, découvrir les documents, normaliser les métadonnées et préserver intégralement hiérarchie, identifiants Drive et URL sources.

OS2 – Extraction documentaire avec provenance
Extraire texte, images, tableaux et équations des PDF / PPT / Word / images, avec provenance au niveau page (*ex. :* « cette information vient de la page 12 du cours de Deep Learning »).

OS3 – RAG de référence puis RAG amélioré
Construire un RAG minimal (requête → plongement → recherche vectorielle → contexte → LLM), l'évaluer, puis l'améliorer (filtrage par métadonnées, reclassement, découpage fondé expérimentalement, citations).

OS4 – Ontologie / graphe de connaissances ENET'Com
Construire un graphe (cours, sujets, concepts, prérequis, exercices, documents, semestres) par extraction semi-automatique validée, et prouver son utilité dans la recherche.

OS5 – RAG augmenté par le graphe
Comparer expérimentalement RAG standard vs. RAG amélioré vs. RAG augmenté par l'ontologie (expansion/affinage de requête, récupération de prérequis et d'exercices liés).

OS6 – Compréhension multimodale
Brancher un modèle vision-langage interchangeable (sans dépendance à un fournisseur propriétaire) pour répondre à des questions sur schémas, diapositives, équations et code, avec évaluation multimodale dédiée.

OS7 – Modèle d'étudiant
Maintenir un état de connaissances léger, interprétable et évolutif par concept (scores, historique, erreurs récentes).

OS8 – Politique pédagogique adaptative (RL)
Formuler l'interaction comme décision séquentielle (état → action pédagogique → récompense de progression), en commençant par simulation/hors-ligne et comparaisons à des baselines (aléatoire, règles fixes, bandit contextuel). Ne revendiquer un gain que sur preuves expérimentales.

Questions de recherche associées : RQ1 (RAG vs. LLM seul et hallucinations), RQ2

(apport de l'ontologie), RQ3 (apport du multimodal), RQ4 (modèle d'apprenant), RQ5 (sélection d'actions), RQ6 (gain d'apprentissage mesurable vs. règles fixes).

Chapitre 4

Description de la base de données

4.1 Nature du catalogue existant

Le corpus n'est **pas** encore téléchargé localement. Le point de départ est un ensemble de **9 fichiers JSON** (dossier `datajson/`) qui cataloguent des dossiers et fichiers Google Drive : `GEC_1st_Year`, `GEC_2nd_Year`, `GII_1st_Year`, `GII_2nd_Year`, `GT_1st_Year`, `GT_2nd_Year`, `IDSD_1st_Year`, `IDSD_2nd_Year`, `LTIC_1st_Year`. Chaque fichier correspond à une filière × année et contient des entrées « semester 1 »/ « semester 2 ».

4.2 Structure hiérarchique observée

```
Semester ("subject": "semester 1")
  -> Subject (ex. "Probabilites")
    -> Subfolder (ex. "proba")
      -> Files (cours.pdf, TD1.pdf, examen.pdf, images...)
```

Champs observés : `subject` / `name` / `id` / `link` / `mimeType` / `icon` / `files` / `subfolders`. Profondeur maximale observée : 2 niveaux, plus un niveau supplémentaire caché dans `files[]` (des sous-dossiers y sont stockés avec `mimeType = application/vnd.google-apps.folder`).

4.3 Statistiques mesurées sur le catalogue

Mesures effectuées sur l'union des 9 fichiers :

Indicateur	Valeur (approx.)
Fichiers catalogue	9
Entrées semestres	18
Nœuds sujets/dossiers (récursif)	232
Entrées fichiers (brutes)	1336
dont sous-dossiers rangés dans `files[]`	191
soit vrais fichiers	$\approx$ 1145
Documents PDF	$\approx$ 739
Documents Word (`docx` + `doc`)	$\approx$ 97
Présentations (`pptx` + `ppt`)	$\approx$ 22
Images (`jpg/jpeg/png/gif`)	$\approx$ 130
Autres (txt, csv, ipynb, xls/xlsx, zip/rar, audio, code)	reste

4.4 Problèmes de qualité à traiter (Phase 1)

— Sous-dossiers mélangés dans `files[]` (191 cas) : la traversée doit inspecter `subfolders[]` **et** `files[]`.

— Dénomination trompeuse : le champ `subject` du niveau racine désigne en fait le semestre ; le sujet réel est le `name` de niveau 2.

— Métadonnées manquantes : $\approx$ 82 nœuds sans `mimeType`, un identifiant racine vide. Valeurs par défaut obligatoires.

— Encodage défectueux (*ex. :* `Probabilitѐs` au lieu de `Probabilités`) : normalisation Unicode NFC + correction prévue.

— Doublons de noms (deux dossiers `proba` d'ID différents) : l'identité est l'ID Drive, jamais le nom.

— Classification par `mimeType` prioritaire sur l'extension (95 fichiers sans extension, formats hétérogènes).

4.5 Schéma normalisé cible

Chaque fichier donne une fiche (le JSON brut reste la source de vérité) :

```
{
  "document_id": "<drive file id>",
  "file_id": "<drive file id>",
  "filename": "cours proba.pdf",
  "mime_type": "application/pdf",
  "source_url": "https://drive.google.com/file/d/.../view",
  "track": "IDSD",
  "year": "1st_Year",
  "semester": "semester 1",
  "subject": "Probabilites",
  "folder_path": ["semester 1", "Probabilites", "proba"],
  "document_type": "course|td|exam|correction|slide|image|other",
  "local_path": null,
  "status": "catalogued|downloaded|processed"
}
```

Les extractions page à page puis les *chunks* prolongent cette fiche (`chunk_id, document_id, page, texte, concepts, plongement`) sans jamais perdre l'URL et l'ID sources.

Chapitre 5

Méthodologie de travail : CRISP-DM

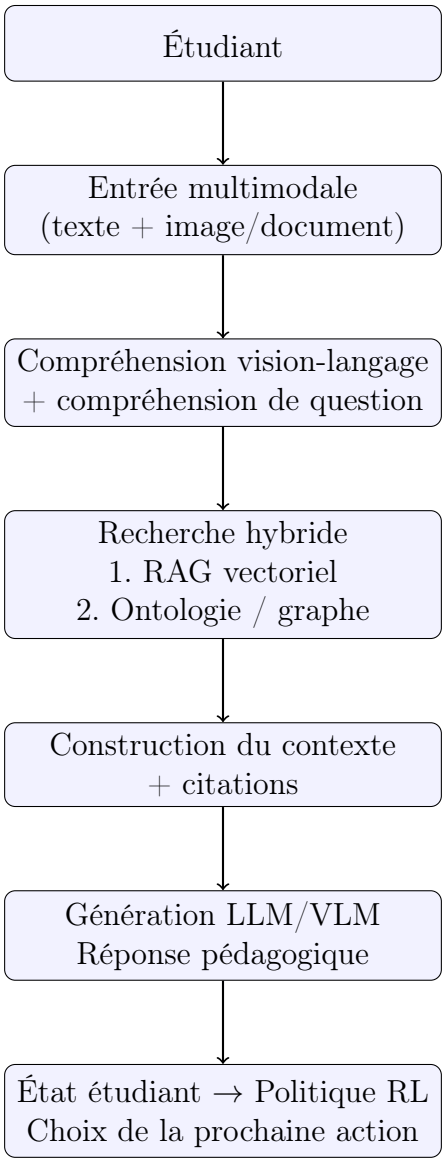
Le projet suit **CRISP-DM**, adapté à un système RAG/ontologie/RL :

1. **Compréhension des objectifs (Business Understanding)**
   Besoins étudiants et enseignants, cas d'usage (« expliquer LSTM », « que faut-il avant PCA ? », « expliquer cette figure avec mon cours de ML »), critères de succès (RQ1–RQ6), contraintes (accès Drive limité, confidentialité, pas de clés en dur, pas d'affirmations non prouvées).
2. **Compréhension des données (Data Understanding)**
   Inspection des 9 JSON (statistiques ci-dessus), typage MIME, échantillon d'un sujet (ex. `proba`), inventaire des doublons et erreurs d'encodage, sondage de téléchargeabilité Drive.
3. **Préparation des données (Data Preparation)**
   Traversée récursive unifiée, normalisation (schéma §4.5), classification `document_type`, déduplication par ID, corpus indexé `corpus_index.json`, téléchargement limité à l'échantillon, extraction texte/image au niveau page.
4. **Modélisation (Modeling)**
   Incrémentale : RAG de référence → RAG amélioré (découpage, reranking) → graphe disciplinaire et RAG augmenté → VLM interchangeable → modèle d'étudiant → politique adaptative (bandit puis RL hors-ligne/simulé).
5. **Évaluation (Evaluation)**
   Par module : rappel/précision/MRR/nDCG (RAG), fidélité/citation (génération), précision des concepts et gain de rappel (ontologie), VQA (multimodal), gain d'apprentissage vs. baselines (RL). Jeux de 100–300 questions ENET'Com validées + cas multimodaux.
6. **Déploiement (Deployment)**
   Intégration finale (application de démonstration), configuration par fichiers/environnement, journalisation des expériences (versions corpus, modèles, chunking, top-k, graines), respect RGPD/confidentialité.

Le cycle est itératif : chaque phase produit une baseline, une évaluation et une décision documentée avant d'ajouter de la complexité.

Chapitre 6

Pipeline théorique (architecture cible)



Actions pédagogiques possibles : expliquer, simplifier, donner un indice, donner un exemple, recommander un prérequis, générer un exercice, augmenter/diminuer la difficulté, poser une question diagnostique, fournir une correction. La récompense reflète la **progression** (+1 exercice réussi ensuite, +0.5 amélioration estimée, 0 neutre, –1 échec répété).

Scénario de démonstration visé : photo d'une architecture LSTM + « Je ne comprends pas le rôle du hidden state »→ détection visuelle, identification LSTM/RNN, recherche dans le corpus Deep Learning, traversée de l'ontologie (prérequis), explication ancrée avec citation page, estimation de compréhension, proposition d'exercice et mise à jour de l'état.

Chapitre 7

Pipeline pratique (mise en œuvre incrémentale)

Phase 1 – Ingestion du catalogue
Un seul `walk()` sur `subfolders[]` + dossiers dans `files[]` ; contexte (filière, année, semestre, sujet, chemin) propagé ; sortie `data/processed/corpus_index.json` + `corpus_stats.json` ; 4 contrôles (ID/URL non vides, hiérarchie préservée, cardinalité, unicité des ID).

Phase 2 – Extraction
Sur l'échantillon uniquement : texte + n° page + images/tableaux/équations (PDF, PPT, Word, texte, images, PDF scannés via OCR si besoin) ; représentation page à page ; validation d'ouverture des fichiers.

Phase 3 – RAG de référence
Requête → plongement → recherche vectorielle → contexte → LLM ; jeu de test 100–300 questions ; métriques Rappel@K, MRR.

Phase 4 – RAG amélioré
Filtrage par métadonnées (semestre/sujet), reclassement, comparaison de découpages (fixe, récursif-sémantique, par page, par titres) choisie sur données ; citations exigées.

Phase 5 – Ontologie
Extraction semi-auto de concepts/relations (`is_a, requires, related_to, taught_in, explained_by`), distinction auto vs. validé ; comparaison RAG vs. RAG+ontologie.

Phase 6 – Multimodal
VLM plug-in (encodeur vision + traitement d'image) ; cas de test schémas/courbes/équations/code exactitude VQA + qualité d'explication.

Phase 7 – Modèle d'étudiant
Scores par concept, historique, erreurs récentes ; signaux (réussite/échec, tentatives, indices, difficulté).

Phase 8 – RL
Seulement si le reste est stable : environnement simulé/hors-ligne, état/action/récompense explicites, baselines (aléatoire, règles, fixe, bandit).

Phase 9 – Assistant final
Intégration et démonstration complète.

Arborescence imposée : `ingestion/`, `rag/`, `ontology/`, `multimodal/`, `student_model/`, `rl/`, `evaluation/`, `app/`, `notebooks/`, `configs/`, `tests/` ; paramètres et clés en fichiers de configuration / variables d'environnement ; chaque expérience journalise (version corpus, modèles, chunking, top-k, reranker, version ontologie, graine).

Chapitre 8

Tableau des livrables

Phase	Livrable	Contenu	Critère d'acceptation
1	Catalogue normalisé	`corpus_index.json` + stats	4 contrôles OK, hiérarchie + URL préservées
1	Échantillon	`sample_proba.json` + fichiers	fichiers ouvrables, pages comptées
2	Extracteur page	texte + images + n° page	provenance page retrouvée
3	RAG baseline	retriever + générateur + config	Rappel@K/MRR mesurés
4	RAG amélioré	reranker + chunking + citations	gain vs. baseline documenté
5	Ontologie v1	schéma + graphe + validés/auto	précision relations + gain RAG
6	Module VLM	connecteur VLM interchangeable	exactitude VQA
7	Modèle étudiant	état + mise à jour	trajectoires cohérentes
8	Politique RL	env. + reward + baseline	comparaison vs. règles, sans surraffirmation
9	Démo finale	app + scénario LSTM	scénario §6 de bout en bout
Transv.	Évaluations	protocoles + jeux + métriques	RQ1–RQ6 renseignées
Transv.	Reproductibilité	configs + journaux	expérience rejouable

Chapitre 9

Ressources de recherche

9.1 Référence structurante : MDKAG

MDKAG : *Retrieval-Augmented Educational QA Powered by a Multimodal Disciplinary Knowledge Graph.* Ressource méthodologique centrale : construction d'un graphe de connaissances **disciplinaire et multimodal** (concepts, relations pédagogiques, ancrage texte–image), puis QA éducative augmentée par récupération conjointe graphe + vecteurs. Le projet ENET'Com en reprend le patron : (i) graphe disciplinaire ancré aux documents locaux plutôt qu'ontologie décorative, (ii) alignement texte–figure pour les schémas/slides, (iii) récupération hybride (sémantique + graphe + métadonnées) avant génération, (iv) évaluation séparée récupération/génération/graphe. Le corpus ENET'Com reste la source de domaine ; MDKAG fournit le cadre, pas les données.

9.2 Autres fondements

— RAG : Retrieval-Augmented Generation (Lewis et al.), DPR, reclassement (cross-encoders, ColBERT) ; chunking récursif/sémantique vs. fixe vs. par page/titres.

— Multimodal : CLIP, BLIP-2, LLaVA / VLM ouverts interchangeables ; benchmark ScienceQA (usage strictement évaluatif, jamais en remplacement du corpus ENET'Com).

— Ontologies éducatives : extraction terminologique, extraction de prérequis, validation manuelle, requêtes graphe pour expansion de recherche.

— Adaptation : traçage de connaissances (BKT/DKT allégés), bandits contextuels, RL hors-ligne/simulé pour politiques pédagogiques ; récompenses de progression.

— Évaluation : Rappel@K, Précision@K, MRR, nDCG ; fidélité au contexte et exactitude des citations ; LLM-juge avec prudence + évaluation humaine (correction, pertinence, clarté pédagogique, usage des sources, hallucinations).

Chapitre 10

Contraintes, risques et reproductibilité

Interdictions : inventer des documents, fabriquer des résultats, prétendre un gain RL sans expérience, ontologie inutilisée, remplacement du corpus par un dataset externe, LLM unique câblé en dur, téléchargement massif aveugle du Drive, exposition de données étudiantes privées.

Risques : accès Drive restreint (mitigation : échantillon + traitement local), qualité OCR/équations (mitigation : évaluation séparée), hallucinations (mitigation : citations obligatoires + fidélité mesurée), complexité RL (mitigation : simulation et baselines d'abord).

Reproductibilité : chaque expérience enregistre version du corpus, configuration de récupération, modèles (plongement, LLM/VLM), stratégie de découpage, top-k, reranker, version d'ontologie, jeu d'évaluation et graine.